

# Trigram based Language Separation for Minority Languages

Jochen Tiepmar

# Language Separation


Prědny redaktor Casnika, Modłański farań Mato Nowka (1812--1864), jo ten wichoraty cas we pšosbje wo spěchowanje na pšuskego ministarja nutśikownego 24. junija 1849 tak wopisował: "In den gefährlichen Tagen des vorherigen Frühlings, wo eine gewissenlose, auf den Umsturz alles Bestehenden hinarbeitende Partei auch in unserer Gegend sich bemüht, die friedlichen Wenden gegen Ordnung und Gesetz aufzuwiegeln, bin ich, und zwar nicht ohne Gefahr, mit der Herausgabe einer Zeitschrift vorgegangen, um die hier eindringenden Erzeugnisse der zügellosen Presse von unseren Wenden fernzuhalten." A Chošebuski krajny ražc, Wjerbański kněžk von Schönfeldt, jo pisał 10. oktobra togo samego lěta na kralojskego ministarja von Mannteuffel: "Die wendische Zeitung wurde von ihnen in einer Zeit begonnen, wo es besonders darauf ankam, die wendischen Bauern vom Taumel zurückzuhalten, der ... in den Bauernstand gebracht wurde. Das konnte durch ein wendisches Blatt vorzüglich erreicht werden, da der Wende außerordentlich viel auf wendisch Gedrucktes gibt ..." Potakem jo se Casnik w lěše bergarsko-demokratiskeje rewolucije z pšuskim, kralozwěrnym wotmyslenim na drogu k swojim cytarjam dał. Weto: Z nim su dali serbskemu ludoju pśeliš wažny srědk za kšusjenje jogo serbskego wjazyma do rukow.

Quelle: Casnikowa cytanka 1848-1899, urn:cts:dsb:casnikowa.cytanka.1848.1899:21-33

# Language Separation & Text Mining

Prědny redaktor Casnika, Modlański farań Mato Nowka (1812--1864), jo ten wichoraty cas we pšosbje wo spěchowanje na pšuskego ministarja nutsikownego 24. junija 1849 tak wopisował: "In den gefährlichen Tagen des vorherigen Frühlings, wo eine gewissenlose, auf den Umsturz alles Bestehenden hinarbeitende Partei auch in unserer Gegend sich bemüht, die friedlichen Wenden gegen Ordnung und Gesetz aufzuwiegeln, bin ich, und zwar nicht ohne Gefahr, mit der Herausgabe einer Zeitschrift vorgegangen, um die hier eindringenden Erzeugnisse der zügellosen Presse von unseren Wenden fernzuhalten." A Chošebuski krajny ražc, Wjerbański kněžk von Schönfeldt, jo pisał 10. oktobra togo samego lěta na kralojskego ministarja von Mannteuffel: "Die wendische Zeitung wurde von ihnen in einer Zeit begonnen, wo es besonders darauf ankam, die wendischen Bauern vom Taumel zurückzuhalten, der ... in den Bauernstand gebracht wurde. Das konnte durch ein wendisches Blatt vorzüglich erreicht werden, da der Wende außerordentlich viel auf wendisch Gedrucktes gibt ..." Potakem jo se Casnik w lěše bergarsko-demokratiskeje rewolucije z pšuskim, kralozwěrnym wotmyslenim na drogu k swojim cytarjam dał. Weto: Z nim su dali serbskemu ludowu pšeliš wažny srědk za kšusnje jogo serbskego wjazyma do rukow.

Language Separation & Cleanup  
improves Text Mining results



# Language Separation

- Approach 1: Detect Minority Language
  - Dismissed because of missing training data
- Approach 2: Detect Majority Language( Dachsprache(?) )
  - Required
    - Training data
    - (Positional) references for text snippets
    - Analysis method

# Language Separation

- Approach 1: Detect Minority Language
  - Dismissed because of missing training data
- Approach 2: Detect Majority Language( Dachsprache(?) ) with high probability
  - Required
    - Training data
    - (Positional) references for text snippets
    - Analysis method

# Language Separation

- Approach 1: Detect Minority Language
  - Dismissed because of missing training data
- Approach 2: Detect Majority Language( Dachsprache(?) ) with high probability
  - Required
    - Training data: German Wordlists (IDS Mannheim, ASV Wortschatz)
    - (Positional) references for text snippets: CTS URNs
    - Analysis method: Trigram based majority language scores for tokens
  - Result
    - Text snippets that contain tokens that are (most propably) majority language markers

# Trigram based majority language separation Step 1 / 3

\* = 3 consecutive tokens

- For each Trigram\*: count majority language tokens using wordlists

| 0                                   |     |  | 1                        |     |   | 2                       |     |   | 3                       |   |  |
|-------------------------------------|-----|--|--------------------------|-----|---|-------------------------|-----|---|-------------------------|---|--|
| punt-20-pń                          | 337 |  | jo-ße-łtało              | 334 | 1 | a-żifchi-k              | 170 | 2 | latin-a-diagonal        | 1 |  |
| głoweżiny-doftachu-nejrédńejfche    | 335 |  | muške-a-golzy            | 334 | 1 | do-1½-lëta              | 170 | 2 | auf-hiefigem-viehmarkte |   |  |
| punt-faréfane-ważeńe                | 331 |  | f-bożaju-pomozu          | 328 | 1 | a-da-ße                 | 169 | 2 | schlachtvieh-waren-auf  |   |  |
| wot-tog-zaða                        | 318 |  | turkojłki-Blewkowy-mus   | 325 | 1 | pla-żandojłkich-rot     | 169 | 2 | waren-auf-hiefigem      |   |  |
| na-hobyma-bokoma                    | 314 |  | schulza-w-chofchebufu    | 323 | 1 | jo-k-tomu               | 168 | 2 | viehmarkte-zum-verkauf  |   |  |
| aż-fchëg-żo                         | 312 |  | sserbłke-a-nimłke        | 322 | 1 | jo-f-woßebnych          | 167 | 2 | hiefigem-viehmarkte-zum |   |  |
| we-tych-haptikach                   | 309 |  | wałńeze-deki-k           | 319 | 1 | fchifchczafńe-jo-a      | 167 | 2 | 100-kilogramm-abo       |   |  |
| worakojz-hujkowa-mudrofcz           | 306 |  | k-nejtuńfchym-plafcheńam | 317 | 1 | w-barlińu-jo            | 166 | 2 | kilogramm-abo-2         |   |  |
| we-bogatem-hufwolowańu              | 305 |  | sbytki-k-hoblakam        | 316 | 1 | żywot-a-te              | 166 | 2 | f-hale-1                |   |  |
| fortow-wot-tych                     | 304 |  | nejłëpfchy-jëżi-fyrup    | 316 | 1 | a-won-ße                | 165 | 2 | do-hale-3               |   |  |
| wałńeze-pořtolowe-ruby              | 304 |  | pořtolowe-ruby-a         | 308 | 1 | poředańe-hubert-ullrich | 161 | 2 | to-pak-jo               |   |  |
| ße-fachadny-tyzeń                   | 303 |  | kejżor-a-kejżorka        | 307 | 1 | max-braune-chuttke      | 161 | 2 | how-a-tam               |   |  |
| přchiruzyjo-we-bogatem              | 301 |  | na-ten-bok               | 306 | 1 | ße-tam-a                | 160 | 2 | a-tak-bu                |   |  |
| na-nowych-wikach                    | 299 |  | kożu-a-friße             | 306 | 1 | w-borkowach-pla         | 160 | 2 | zum-verkauf-angetrieben |   |  |
| ssobuzłonk-chofchebufkeg-rabattoweg | 298 |  | deki-k-přchikfchyfchu    | 306 | 1 | a-to-wot                | 157 | 2 | a-to-f                  |   |  |
| ullrichowe-felowe-wino              | 297 |  | ruby-a-kfchyfcha         | 306 | 1 | a-aż-jo                 | 156 | 2 | 15-f-hale               |   |  |
| ßam-ßa-ße                           | 296 |  | do-barlińa-3             | 306 | 1 | a-to-na                 | 155 | 2 | a-jo-f                  |   |  |

\* Trigram lists here already include Future Work improvements

# Trigram based majority language separation Step 2 / 3

- List tokens that are found **exclusively** in maximum language score trigrams

| 0                                       | 1                               | 2                              | 3                       |
|-----------------------------------------|---------------------------------|--------------------------------|-------------------------|
| punt-20-pá 337                          | jo-be-flalo 334 1               | a-ziŕchi-k 170 2               | latin-a-diagonal        |
| gloweżiny-doftachu-nejrédnejŕche 335    | muŕke-a-golzy 334 1             | do-1½-lěta 170 2               | auf-hiefigem-viehmarkte |
| punt-larélane-ważeńe 331                | f-bożeju-pomozu 328 1           | a-da-be 169 2                  | schlachtvieh-waren-auf  |
| wot-tog-zaŕa 318                        | narkojŕki-flęwkowy-mus 325 1    | pla-žandojŕkich-rot 169 2      | waren-auf-hiefigem      |
| na-hobyma-bokoma 314                    | ŕchulza-w-choŕchebuŕu 323 1     | jo-k-tomu 168 2                | viehmarkte-zum-verkauf  |
| až-ŕchěg-žo 312                         | ŕŕerbŕke-a-nimŕke 322 1         | jo-f-woŕebnych 167 2           | hiefigem-viehmarkte-zum |
| we-tych-haptikach 309                   | walŕneze-deki-k 319 1           | fchifchczatŕie-jo-a 167 2      | 100-kilogramm-abo       |
| worakojz-hujkowa-mudroŕč 306            | k-nejnuŕfchym-plaŕcheŕnam 317 1 | w-barliu-jo 166 2              | kilogramm-abo-2         |
| we-bogatem-hufwolowaŕu 305              | sbytki-k-hoblakam 316 1         | żywot-a-ie 166 2               | f-hale-1                |
| fortow-wot-tych 304                     | nejlěpfchy-jězi-fyrup 316 1     | a-won-be 165 2                 | do-hale-3               |
| walŕneze-poŕolowe-ruby 304              | poŕolowe-ruby-a 308 1           | požedaŕie-hubert-ullrich 161 2 | to-pak-jo               |
| be-lachadny-tyžeŕ 303                   | kejžor-a-kejžorka 307 1         | max-braune-chutke 161 2        | how-a-tam               |
| piŕchiruzyjo-we-bogatem 301             | na-ten-bok 306 1                | be-tam-a 160 2                 | a-tak-bu                |
| na-nowych-wikach 299                    | kožu-a-friŕe 306 1              | w-borkowach-pla 160 2          | zum-verkauf-angetrieben |
| ŕsobuzlonk-choŕchebuŕkeg-rabattoweg 298 | deki-k-piŕchikfchyŕchu 306 1    | a-to-wot 157 2                 | a-to-f                  |
| ullrichowe-felowe-wino 297              | ruby-a-kfchyŕcha 306 1          | a-až-jo 156 2                  | 15-f-hale               |
| ŕam-ŕa-ŕa 296                           | do-barliu-3 306 1               | a-to-na 155 2                  | a-jo-f                  |



volkstümlichen 66  
 rechtspflege 66  
 beeinträchtigt 66  
 mittelpreise 60  
 seifen 58  
 erzielen 56  
 trade 56  
 gefangbücher 55  
 garantie 54  
 diskret 51  
 packetfahrt 51  
 feiner 50  
 seefisch 50  
 einzig 48  
 größtes 47  
 holl 47  
 erfchienen 46  
 produkten 45  
 cajüte 43  
 zutriften 42



# Trigram based majority language separation Step 3 / 3

- List text snippets that contain **these tokens**

|                |    |                                                                                                |
|----------------|----|------------------------------------------------------------------------------------------------|
| volkstümlichen | 66 | urn:cts:dsb:bramborski.sserski_zassnik.1873.47:7.2→p→Den Reichs- und Staatshaushalt, prakt     |
| rechtspflege   | 66 | urn:cts:dsb:bramborski.sserski_zassnik.1873.47:7.3→p→Der Kalender ist bekanntlich immer re     |
| beeinträchtigt | 66 | urn:cts:dsb:bramborski.sserski_zassnik.1873.47:9.2→p→An Schlachtvieh waren auf hiefigem V      |
| mittelpreise   | 60 | urn:cts:dsb:bramborski.sserski_zassnik.1873.48:5.5.1→p→Spielwerke von 4 bis 120 Stücke         |
| <b>seifen</b>  | 58 | urn:cts:dsb:bramborski.sserski_zassnik.1873.48:5.5.2→p→Spieldofen von 2 bis 16 Stücke f        |
| erzielen       | 56 | urn:cts:dsb:bramborski.sserski_zassnik.1873.48:5.6.1→p→Tinten in schwarz, blau, roth, g        |
| trade          | 56 | urn:cts:dsb:bramborski.sserski_zassnik.1873.48:6.2→p→An Schlachtvieh waren auf hiefigem V      |
| gefangbücher   | 55 | urn:cts:dsb:bramborski.sserski_zassnik.1873.49:5.5.1→p→Spielwerke von 4 bis 120 Stücke         |
| garantie       | 54 | urn:cts:dsb:bramborski.sserski_zassnik.1873.49:5.5.2→p→Spieldofen von 2 bis 16 Stücke f        |
| diskret        | 51 | urn:cts:dsb:bramborski.sserski_zassnik.1873.50:3.4.1→p→Bei Anna Lehmann in Stöbitz ist         |
| packetfahrt    | 51 | urn:cts:dsb:bramborski.sserski_zassnik.1873.50:3.5.1→p→Neue Flügel aus Leipzig zu Fabril       |
| feiner         | 50 | urn:cts:dsb:bramborski.sserski_zassnik.1873.50:3.6.1→p→R. Simke, Berliner Chauffeefstraße      |
| seefisch       | 50 | urn:cts:dsb:bramborski.sserski_zassnik.1873.50:3.6.2→p→Zwirnspitzen, feidenes Band, Tül        |
| einzig         | 48 | urn:cts:dsb:bramborski.sserski_zassnik.1873.50:3.8.1→p→Beften trocknen Haidegrütze empfe       |
| größtes        | 47 | urn:cts:dsb:bramborski.sserski_zassnik.1873.50:4.2→p→An Schlachtvieh waren auf hiefigem V      |
| holl           | 47 | urn:cts:dsb:bramborski.sserski_zassnik.1873.51:4.6.1→p→Petroleum, Lichte, <b>Seifen</b> empfie |
| erfchienen     | 46 | urn:cts:dsb:bramborski.sserski_zassnik.1873.51:4.7.2→p→vis - à - vis dem königl. Landrat       |
| produkten      | 45 | urn:cts:dsb:bramborski.sserski_zassnik.1873.51:4.9.1→p→Neue Flügel aus Leipzig zu Fabril       |
| cajüte         | 43 | urn:cts:dsb:bramborski.sserski_zassnik.1873.51:4.10.1→p→Sämmtliche Gewürze als: Muskatbli      |
| zutriften      | 42 |                                                                                                |

# Result for 1 Document

- Tokens that are found **exclusively** in maximum language score trigrams

nowiny pčhuška kralowka hudowa halčhbetha manželka **lamřeteg** krala friedr wilhelma iv laży we dreždżanach pla šwojeje šotfche na šmerich chora wona běcho do dreždżan drogowała aby tam šwoju šotfchu **trořchtowała** kotraž pčhes tu šmerich **sakřkego** krala teke jo hudowa hordowała nafh kejžor jo zek bogu fašej řtowy s franzojkeje marřhall bazaine bu wot šwojog řudnikřwa k řmerich **fašřnzony** mac mahon pak jo tu fchtrofu do **20 řetneg** popajřenřtwa pčhemenř tež šwoje wojarřke mēna řgubijo bazaine to zele pčheřřuchowane tych řnankow nejo jomu howak řednu winu hopokafalo ako to zoř fchykne druge franzojke generale teke řu zynili **bazainowy** řeznik hopokafa až won hynazej zynilich namořafcho ak zynit jo tež pryzn friedrich karl jo dwa řilřa pořřařa a hopořnani až bazaine nejo pčhi nom byř fcho podermo ten franzojki lud zo mēřh jadnego na kotregoř fchyknu winn tog řejgrařcha mořo walřch a tak muřy bazaine řcherpēř pčhawdořcz pořwřřno ten lud ale ten grēř jo tych řuži řkafene franzojke řudniki řejřu ten řchpruch nahuknuli to řmy na řich řuřeru juř zelfo wiřeli **bazainowy** prozeř na **7** dez chopi **bazainowy řeznyk řachaud** tog **pčhelřkarřžoneg** řagranařch won groni jo ten nejřchwalobnejřchy nafhych wojakow pčheradnik bazaine jo zynit zoř napoleon jomu jo pčhikafařa napoleon řam jo jomu we tom nimřkem popajřenřtwa pčhawe řař general trochu řam grořafcho až nēto to a druge **gramřřwo** řchu winu na nekotarych hufchřkow chyta tu zelu winu **majute** kenž k tej wojne řu řchczuwalu a ten zely franzojki lud kotryř řřym jo řkēřel chwalbu řněřh te generale changarnier canrobert a druge huřřoke muře řu řjawne **bazaina** chwalili juř řla řogo wojnow we afrize ruřřojkeř a mexize jo won chwalbu řořař wot kralow a werchow chto řu nēto te kenž **pčhelřkarřžene** řu **porořili** dwa **bazainowej** winika oberřř d aulau a **oberřřlieutnant villenoilly** a to togodla až bazaine nej řima řořcz zelfcz řař a řima te myřchyny napořnit zoř tu řitwu pla řorny na **14** aug **1870** nařřpa ga jo bazaine tak do hogna řcheř až fchykne řu ře řiwalu kenž to řu wiřeli tejerownořcz jo ře na **16** aug řřalo pčheradniki pak **nēpowdaju** řdobreju wolu řwoju hufřchobu tym **kulam** ten **18** aug jo řere negluzny byř fa nafhcho wojņřtwo weto pak řmy řchu zelfcz řněři a tež dwē kanuře dobyli konz pčhřzo we řchpanřkeř kņēży ře řbēř a wojna pčheze jadrnak glich jo to grořene noweje wojny ře wotchylřo dokulž amerikařka a engellka řegierunga řczepnořcz matej we engellkeř řarže ře welike řgromařiny we kotryřčž tejerownořcz na to **pčhiberane** katholickeje **pořednořcz** ře pokařujo ta engellka řegierunga hordujo **wabřona** aby fa zařřa byřřhej wozy mēla tež nimľkeř řegieruře **zeju** wone řgromařiny adreřřu pořřařch a ju k huzarřanu we tej wojne pčhelřchwo tych katholicřch napominařch **kowalowy** towarřřch ras kowal borřchu mējařcho kenž pomařem zēřafcho gař pak ře zēřcho k řlidoju ga welgi chwatař jo ten předny běcho do řchklē řutřch a řředny wenze řař tak pilny nicht nej w dome byř ak borřcha kuřdy ras ras mējřřar groni towarřřch to rosmēřch namogu řchak jo to řřare pčhřřřowu a řnate kuřdemu tak ak ře jē tak zēřa ře ty pak řy wetom řhynakřchy nicht tak pomařem neřēřa a řerjo tak ak ty no řařcho borřcha to řre wēm glich dořy řpodk grund to ma jēř trajo krotko zēřo pak mam až do wjazora gab nēchten řejař zely řen řřařch mimo **pčheřřařcha** ga by nařředku **řnřlowař** niz mēnej ako ja **řappow** te robe řchi wiře na druge řajřřcho zēřcho hanko řwjařřelim do teje huzby won běcho řebe we wernolcz **předkwēřel** až zo ře řere **řazarřařch** a nēzo dořego nahuknuřch řcho zoř ten knēs jomu řakafcho zřnafcho won řařřobn a kradu a tak řu ř nim řche řřokojom řapředka pak řechu jomu te nejřřřfche zēřa pčheřowdane byli pořřēj **řmējařcho** won tež pčhedawařch to běcho jomu welgi lubo ale hanko hanko řlējař ře předk řin pčhawe řapředka řu te rořyny a ten zukor kenž na nog tak milne **pogľēduju** a hanko nebēřcho řajřřcha řjatowař nēwēř nařř do řpyřowařa won řyķnu jadrnu **řjarřcz** a pon dwē do kapře řkřhajzu až nicht jo nehupyta a řařla je rowno tak potajmne tež do guby a to řechu ras doře we tych **kafchczřkach** ga nebēřcho niz wiřelch te řechu polne wotergi bu hanko tež ř worami řam a how do domu pořřany a won křyřnu młogi řylber k pčheřpřchoju **zari** řebe te řylbery ty **poderbřřch** nowu kapu a ja řchi řamgu ředneje kupřřch tak napominařcho jog ta moterka a won běcho pořřřřchny po krotkem zařřu mējařcho juřo řolař a řwjařřelim pokařowařcho won řen řwojomu **řowarřřchoju** juř řenřamy wjazor pojedafcho jomu ten towarřřch aby ř nim řobu do kjarřmy řcheř řlařk piwa řit hanko ře řapředka řonachafcho pčheto won wēřefcho kak **řřebne** řwoj řolař poderbēřcho to řchi ředēj niz řařchēřch wotgroni ten towarřřch ja řdu řchi řlařk piwa řařřch telik řyřchczř mam hanko zo řobu řinř a wiřřche a potom kuřdy řen tak řejřno ak ta řoda jo řamřřona ale ak řen wjazor mimo mējařcho won wele wēřej řařařchřch ako řaden řlařk kak to jo řlējař tam běcho tych młoenřzow řyřchczř wēřej a řim bu řen zařř řlujki řogdla chopichu řotowařch woni **nēřřajřchu** wele ale dokulž nafh hanko řkoro kuřdy ras řejgra ga běcho řogo řolař řkoro huleřcheř a hufchēj tog běcho řyřchczř řaden winowaty ale won nēmējařcho řednych řeřes a řogo moterka teke niz řogo moterka bořko **natu** nekēřchēřcho ře lubej řewřřchym myřřřřch won ře řřoma řej pčhed wezy řřupřch a gař wona řkjarřy a pčhařcha řogdla won nēto pčhezeř tak pořřē domoj pčhřzo ga ma won řchake **řagrona** a nařředku ře řeje lubej hobiař aby řeje řly **nēwřřel** neřelu nej won ředne wēřej řichy aby pčhi nej pořřējcheř a ju potofchřowař won muřy zynilich zoř te towarřřch jomu kařu pčheto won ga jo řich řlōuřnik a boj ře pčhed nimi řokulž řomu řřym a drugim groře zoř nēřzo řen řřug řařařchřch zo řej řachopřřch **řnateřynyēřa** ta **pořřzarska** řgromařina wofřchuřř verein w řpřřu řero kuřdy řen řeře na řař a dajo wot hundred pēřch řani **5** zek bogu wona řřoj na řwardych nogach pčheto k nej řřřřchaju **250** pčhemořne muře kotare řche gromařu ře řwojřm zelyřm pčhemořenim tu řgromařinu řařřupe a řa te **pořřzonne** pēřeře řřoje stare řřwřařřke řnigly řiblijē a druge řnigly horduju nejřlepeř pčhewēřane we řej řchřřchczarři tog řw brandta w řhōřchēbulu **řmřnyľkeř** řařřy **22** we wřchyķnych **knēřřwojřřch** a **nekēřřwojřřch** **nařřupnořczach** dajo dořru řadu a napřřcho tež řkjarřby a piřřma kař řan byřch řeje ten řudnikořki aktuar ře řřuřby řunřřřer pla **řandřgerichřy** **346** řen nejřřēpchy bog kotaregoř řaden tomu drugemu hobrařřch mořo nejo niz drugogo ako te řřatkarřke řnigly wot **řefchnara** řere huwēřane ku krodņēřu pla řw brandta w řhōřchēbulu **řmřnyľkeř** řařřy **22** petroleum lichte **řeifen** empřieřt die droguenhandlung von ř schwarz groře marktřraře ř ř řimke berliner řhauffēēřraře **3** řis a řis dem kōņigľ **řandřrřsante** empřieřt den geeřřten **řandbewohnern** zu spott přeifen zwiřnřřřzen **řeidenes řand** řüllřřcher weiře zeuge in allen **řreiten** mit und ohne **řlūmchens** zu **řřchern** řařře řeinwand řettinřette zichenzeuge kattune und piquē ř **řarachente** řofenzeuge řowie alle wollene řachen ř řimke berliner řhauffēēřraře řis a řis dem kōņigľ **řandřrřsante** řorauer kalender řind zu haben řei řw brandt mřhlenřř **22** neue řřgel aus leipzig zu řabrikpřeifen neue řianino s eigner řabrik **10** řgar **řantie** **175** **350** řřřl gebrauchte řianino s řřgel und **řařellōřteřpiano** s řut repair empřieřt g řahmann berlin alexanderřraře **22** řř **řařmřřřliche** gewřrce als **řuskatblřthe** řimmt **řtemanis cardeman** řofinen řandel **řitronēřl** etc empřieřt die droguenhandlung von ř schwarz groře marktřraře ř der neue reichs mark **řechner** im portemonnaie von w řorenz zu haben řur **1** řgr řei řw brandt mřhlenřř **22** **řeihnachts** anzeigē řur die **řeihnachtszeit** řřt mein řager von kinder und **řugendřřřřten** in mehr als **40** řorten von **1** řilbergrořchen an řis zu **2** řřalem vollřřřđig verřehen řchul artikel řchul und **řchreibebřcher** mit und ohne řiniatur von **6** řř an **řzeichnen** řheřte řederkalfen in řolz řappe und ředer von **1** řgr an **řleifedem řřahľfedem řederhalter řchiefertafeln řchiefertřřte** kanteľ und řlineale **řordinare** polřre und mit dem neuen metermař verřehen řařmřřliche řier gebrāřchliche **řelang** und **řchulbřcher** dauerhaft **řebunden** und zu den řilligřten přeifen etc **řederwaaren** als photographie und řchreib album von **5** řgr an řrief und řchreibmappen notizbřcher řřeifřařch etc zur anřertigung von **řeihnachts** gegenřřanden empřieře ich alle řorten **řinfache** und bunte papiere als marmor ařhat řhagrřn gold řilber řach und **řziggelřein** papier etc gold und řilberborten **řilberbogen** modēľřibogen ankleidepuffen und verřchiedene andere artikel in grōřřter auswahl řerner **řappen řstickereien** an **řeihnachtsřelchenke** werden řchnel und řauber angebrakalten řalanterie amp kurzwaaren dwerfe **řipplachen** řandřřch und cigarrenkalfen **řulřkalfen** von **6** řř an řarben řinřel řchwarze řilber zum **řařmalen** papetereien gold und řilberřřchaum alle řorten kalender **řontobřcher** mit und ohne řiniatur zu řabrikpřeifen photographie **řahmen** řpiegel etc řchlieřřich empřieře ich mein grōřēs papier řager von **řconcept** canzlei řrief und **řzeichnen** papiere in allen gattungen **řvertreten** řouverts in allen grōřřen řw brandt mřhlenřřraře **22**

# Results

- Input
  - Lower Sorbian Text Corpus (4618 documents), German wordlists
  - **No sorbian language knowledge or training data**
- Generic results
  - 4276 text snippets in 1512 documents
  - 228 false positives
- (Several iterations of) tweaked wordlists & false positive token list
  - 5052 text snippets in 1526 documents
  - 107 false positives

# Future Work

- Step 1: For each Trigram count majority language tokens using wordlists
  - Future Work: Wordlists, False Positives, Other ngram types, Iterative tweaking based in intermediate results,...
- Step 2: List tokens that are found exclusively in maximum language score trigrams
  - Future Work: More flexibility?, Ignore lists (digits, entities...), ...
- Step 3: List text snippets that contain these tokens
  - Future Work: Other kinds of snippets (sentence, semantic units, POS phrases),...

# Thank you for listening

Dr. Jochen Tiepmar

Sorbisches Institut Bautzen

jochen.tiepmar@serbski-institute.de

DSB Wortschatzportal

<https://tiepilab.de/dsbwortschatz/>

Canonical Text Infrastructure

<https://urncts.eu/>